

DOI: 10.3969/j.issn.1001-3881.2023.05.006

本文引用格式: 张宇廷,王宗彦,李梦龙,等.基于机器视觉与 Faster-RCNN 的 Delta 机器人工件识别检测[J].机床与液压, 2023,51(5):35-40.

ZHANG Yuting, WANG Zongyan, LI Menglong, et al. Workpiece recognition and detection of Delta robot based on machine vision and Faster-RCNN [J]. Machine Tool & Hydraulics, 2023, 51(5): 35-40.

基于机器视觉与 Faster-RCNN 的 Delta 机器人工件识别检测

张宇廷^{1,2}, 王宗彦^{1,2}, 李梦龙^{1,2}, 赵鹏宇^{1,2}

(1. 中北大学机械工程学院, 山西太原 030051; 2. 山西省起重机数字化设计
工程技术研究中心, 山西太原 030051)

摘要: 针对传统并联机器人在工作环境中存在抓取不精确、定位与分类识别效率低下的问题, 提出一种基于机器视觉与 Faster-RCNN 神经网络的工件识别检测技术。采用 Delta 机器人实验平台采集图像, 进行图像的预处理操作并将其添加至网络训练集。通过 Python3.7-torch1.7 搭建深度学习中的 Faster R-CNN 卷积神经网络, 作为基本框架训练工件图像数据集。最后将训练后的卷积神经网络得到的工件检测结果与原实验工件识别系统对比。结果表明: 改进后的识别平均精确度比原有识别系统有所提高, 反应时间缩短, 并且能识别不同类型的工件。

关键词: 并联机器人; 深度学习; Faster R-CNN; 图像处理

中图分类号: TP242.2

Workpiece Recognition and Detection of Delta Robot Based on Machine Vision and Faster-RCNN

ZHANG Yuting^{1,2}, WANG Zongyan^{1,2}, LI Menglong^{1,2}, ZHAO Pengyu^{1,2}

(1. School of Mechanical Engineering, North University of China, Taiyuan Shanxi 030051, China;
2. Shanxi Crane Digital Design Engineering Technology Research Center, Taiyuan Shanxi 030051, China)

Abstract: In order to solve the problems of inaccurate grasping and low efficiency of localization and classification in the working environment of the traditional parallel robots, a detection technique of workpiece recognition based on machine vision and Faster-RCNN neural network was proposed. they were collected by the parallel robot experimental platform, they were preprocessed then added to the network data set. The Faster-RCNN convolutional neural network in depth learning with Python 3.7-torch 1.7 was built as the basic framework for training workpiece image data sets. Finally, the workpiece detection results obtained by the trained convolutional neural network were compared with the original test workpiece identification system. The results show that the improved recognition average accuracy is better than the original recognition system, the reaction time is shortened and different types of workpieces can be recognized.

Keywords: Parallel robot; Deep learning; Faster R-CNN; Image processing

0 前言

目前, 人工智能与机器人工业紧密结合, 尤其是机器视觉与深度学习已经成为了新时代工业智能机器人的重要发展趋势。其中机器人领域运用神经网络较为广泛的是串联机器人与医疗手术机器人, 通过深层神经网络的迭代计算与自适应的训练过程, 物品检测与图像识别效率大大提高。

对于工件识别而言, 杨桂华等^[1]利用卷积神经网络与分类器相结合的方式对工件进行识别, 节省了定位时间; 梅江平等^[2]设计基于单目视觉的并联机器人动态目标跟踪算法, 提高机器人定位精度; 王彦^[3]将机

械臂的双目视觉与遗传算法结合使得图像识别更加清晰明了, 为后来计算机视觉与算法结合提供参考。并联机器人通常适用于食品包装、物料分拣等场合^[4-6], 工件的特殊位姿、本身的形状复杂、传送带高速运转都使得抓取效率大幅降低^[7]。在并联机器人中, 由于自身工作空间的约束以及单双目视觉识别标定的复杂性, 并联机构与视觉神经网络研究较少。

本文作者提出了一种基于深层卷积神经网络的物体定位方法, 可以快速精确定位与识别传送带上的各种工件。首先, 在 Delta 机器人实验台中, 对采集到的数据信息进行预处理; 然后不间断拍摄相关工件各

收稿日期: 2021-12-02

基金项目: 山西省重点国际科技合作项目 (201903D421015)

作者简介: 张宇廷 (1997—), 男, 硕士研究生, 研究方向为机器视觉与神经网络研究。E-mail: 2397618885@qq.com。

通信作者: 王宗彦 (1963—), 男, 博士, 教授, 研究方向为智能制造与数字化。E-mail: iawangzongyan@sina.com。

个位姿的图片信息,训练 Faster R-CNN 卷积神经网络调整相关参数,实现深层卷积神经网络能够根据图像识别不同工件;最终对原有视觉系统与改进后的神经网络识别进行大量对比实验,判断其可靠性。

1 图像预处理

图像预处理是机器视觉与神经网络中最为关键的一环,图像质量的好坏直接关系到工件的识别精确度、数据集的制作以及神经网络训练^[8]。得到的图像按原始图像、数据增强图像、处理图像 4.5:4.5:1 进行操作。文中所采用的关键步骤有图像的灰度变换、阈值分割、算子边缘处理等操作,使用的图像预处理软件为 MATLAB 与 OpenCV,具体预处理步骤如图 1 所示。

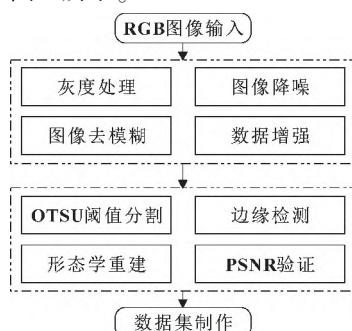


图 1 图像预处理步骤

Fig. 1 Image pre-processing step

摄像头拍摄到的是三通道的 RGB 图像,经过灰度处理后变成单通道的灰度图像,某些图像可能存在噪声干扰,需要通过空间滤波实现图像降噪。将部分图片输出到数据集,再进行阈值分割得到二值化图像;对它进行 Canny 边缘识别,通过形态学的重建,例如开运算与闭运算的处理,得到需要的工件效果图后再次输出到数据集。

1.1 图像采集与灰度变换

采用的实验平台为 Delta 并联机器人搭载安装有 CCD 工业相机作为图片采集工具,相机固定在 Delta 机器人的静平台前端,能够第一时间捕捉到传送带上工件的位置,减小实验误差,启动高速传送带模拟实际工况。图 2 所示为采集图像平台。




图 2 图像采集平台

Fig. 2 Image acquisition platform

采集工件图像样本为 500 张,需要进行图像的灰度转换,图像训练集需要大约 1 500 张工件图像。图 3 所示为采集到的 RGB 部分原始图片,传送带需要

进行降噪去模糊等预处理操作。



图 3 数据集部分原始图片

Fig. 3 Raw images of the data set section

灰度处理将 RGB 图像转换为单通道的灰度图像,尽可能保证了图像的清晰度。使用对比拉伸函数为

$$I(x, y) = \frac{I(x, y) - I_{\min}}{I_{\max} - I_{\min}} (I'_{\max} - I'_{\min}) \quad (1)$$

其中: I_{\min} 、 I_{\max} 分别为最小灰度值和最大灰度值; I'_{\max} 、 I'_{\min} 分别为要拉伸到的灰度空间的灰度最大值和最小值。经过处理可得到工件灰度图像与直方图分布如图 4 所示,直方图的范围大部分集中于 $[0, 50]$ 的黑色区间与 $[100, 200]$ 的灰度值区间,符合使用条件。




图 4 灰度转换结果

Fig. 4 Grayscale conversion results: (a) work piece grayscale image; (b) grayscale histogram distribution

1.2 阈值处理与图像降噪

阈值处理是图像分割的关键,神经网络在判断图像的时候,会根据基础轮廓进行判断并且给出预选区域。例如图 3 所示灰度直方图可以表示为工件图像函数 $f(x, y)$,工件图像又分为深色的背景图像与浅色的工件目标图像,提取相应工件的方法为选择合适的阈值 T ,当 $f(x, y) > T$ 时为 (x, y) 的目标点,否则为背景点。文中使用 OTSU 全局阈值处理,能够有效根据特定图片自主判断图像阈值。图 5 所示为二值化图像对比,虽然损失了部分钻孔特征,但是得到了较为完整的工件边缘。




图 5 二值化对比

Fig. 5 Binarized contrast: (a) normal; (b) OTSU optimization

由于光源亮度、工作环境中灰尘以及高速传送带运行捕捉图像模糊的因素,工件图像可能会出现噪声干扰,并且无法避免。图6(a)(b)所示为光照不均造成的失真现象与模糊图像造成的类似椒盐噪声干扰。

对于上述这种情况,需要尽可能消除噪声。采用空间噪声滤波器中的中值与高斯滤波,将噪声点用周边的各点像素中值代替,剔除孤立噪声点,能够有效处理椒盐噪声,得到较为清晰的图像,如图6(c)所示。




图6 工件图像降噪

Fig. 6 Workpiece images noise reduction: (a) image distortion; (b) salt and pepper noise; (c) noise treatment

1.3 图像边缘识别

工件图像的边缘识别通常采用到的方法有 Prewitt 检测、Laplacian 算子检测、Sobel 检测以及 Canny 算子检测。通常情况下想要得到相对完整的边缘轮廓区域,且要求边缘识别效率更高,一般通过 Canny 检测算子实现整个过程。图7所示为 Canny 边缘检测与形态学重构结果。



图7 Canny 边缘识别

Fig. 7 Canny edge recognition

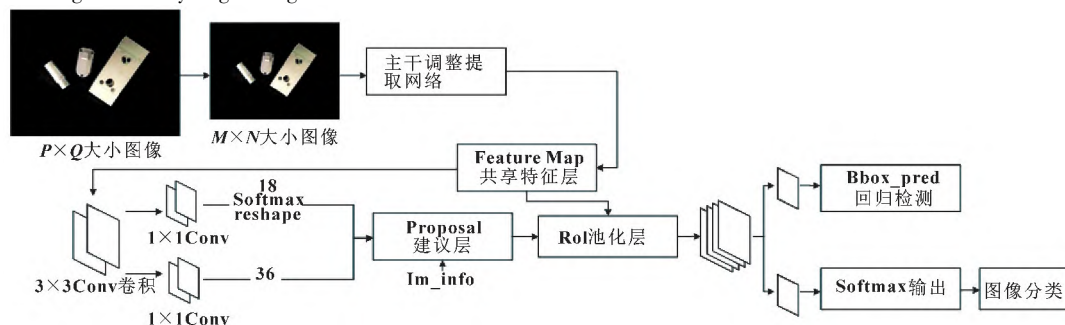


图8 Faster R-CNN 基本模型

Fig. 8 Basic model of the Faster R-CNN

Canny 算子边缘计算在高斯滤波消除噪声过后,会计算图像的局部梯度与边缘方向,对于非边缘的像素采用非极大值抑制,保留线性边缘线段,对于工件本身而言,只需要识别基本轮廓即可,因此采用了 3×3 的卷积核进行了操作。

2 网络模型搭建

2.1 深度学习理解

深度学习是机器学习的深层次运用^[9-11],可以解决图像处理中的“贡献度分配问题”,即图像的前景中目标与背景的识别,通过整个学习模型得到最终的可视化信息。与机器视觉最契合的深度学习模型就是卷积神经网络模型。文中深度学习的定义是指高层次机器学习下的卷积神经网络模型多层前馈网络,通过反复训练实现工件图片识别检测功能。

2.2 Faster R-CNN 神经网络模型搭建

卷积神经网络 (Convolutional Neural Networks, CNN) 适用于二维、三维与多维高阶数据处理,不同于 MLP 学习模型单一的运行模式,它还具有实现半监督式与无监督式学习的功能。传统的 CNN 模块包括卷积层、池化层、权重层、全连接层等,对于图像识别定位而言还需要池化层带有感兴趣区域 (Region of Interest, RoI),能够使用标定框精确定位目标,因此 RoI Pooling 的实现尤为重要。

而当下最契合工件识别定位的神经网络模型为基于区域的卷积神经网络 Fast R-CNN 与 Faster R-CNN^[12]。工件标定的背景无其他噪声干扰,以及经过了预处理图像阶段,这2种深度学习模型针对每个区域进行判定后,使用非极大值抑制操作远大于设定的阈值,显著提高工件识别精度。但是由于 Fast R-CNN 对象检测很慢,其运行效率也会因为数据量受到 CPU 的限制,而在工业环境中 Delta 并联机器人的运动方式是以快速精确稳定而著称。高速传送带下的工件需要相应的反应速率,而 Faster R-CNN 弥补了 Fast R-CNN 的缺点,使用了 RPN 区域建议网络,产生的建议框与图像识别共用卷积特征,训练时间更短、效率更高。图8所示为构建的 Faster R-CNN 基本模型。

Faster R-CNN 工件识别的思路为输入图像大小为 $P \times Q$ 的工件图片, 预处理为 $M \times N$ 大小的图像, 通过主干特征提取 ResNet50 残差网络大小提取数据集中的工件特征, 输出相应的工件特征向量到共享特征层来进行图像的划分与特征向量处理。通过 RPN 网络, 进行 3×3 卷积的滚动窗口遍历整个共享特征层进行特征整合, 18 通道需要重构后到达 Proposal 层, 卷积网络中 Anchor 为 9 个, 并把它们拆分为背景值与前景值。Proposal 建议层会对画面中的物体进行粗略筛选, 经过卷积层共享特征用 RoI Pooling 层固定全连接层的输入维度。最后通过池化层的共享特征层进行 Bbox 回归预测与分类检测, Im_info 为回归预测回馈优化建议框的结果, 最终识别出相应的工件图片。

2.3 Faster R-CNN 损失函数

在深层的网络训练中, 为了预测现有卷积网络的训练质量好坏, 需要考虑到损失函数, 它会在训练中不断地优化。一共在 Faster R-CNN 中产生 2 种损失, 分别为分类损失与回归损失。Faster R-CNN 总损失函数的数学模型为式 (2):

$$L(P_i, t_i) = \frac{1}{N_{\text{CLS}}} \sum_i L_{\text{CLS}}(P_i, P_i^*) + \frac{\theta}{N_{\text{reg}}} \sum_i P_i^* \cdot L_{\text{reg}}(t_i, t_i^*) \quad (2)$$

式中: P_i 为预选框中存在目标的概率; P_i^* 为真实存在目标的概率; t_i 为预选框距离真实目标预测的偏移距离; t_i^* 为标定框距离真实目标预测的偏移距离; N_{CLS} 为分类参数; N_{reg} 为回归参数; θ 为调整参数, 为了让 2 个损失比重趋于相同; L_{CLS} 为分类损失; L_{reg} 为回归损失。

2.3.1 回归损失

Faster R-CNN 会对预选框进行预测, 一般的神经网络可以使用 L_2 损失函数, 即平方损失函数公式 (3), 这样得到的结果误差较大, 并且可能导致极端误差, 对于并联机构来说, 可能会使抓取精度降低。为缓和预测结果的不稳定性, 采用 L_1 损失函数公式 (4) 则会随着误差线性增加, 但是在 x 趋向于 0 的时候结果不收敛, 解集存在不稳定性。

$$f(x)_{L_2} = x^2 \quad (3)$$

$$f(x)_{L_1} = |x| \quad (4)$$

为了保证并联机构正逆解与位置偏差降低, 采用 Smooth L_1 损失函数模型[式(5)], 在函数趋于 0 的附近使用平滑函数, 通过参数 σ 来控制它的平滑程度, 正常情况下 $\sigma=1$ 。

$$L_{\text{reg}}(t, t_i^*) = \text{SmoothL}_1(x) = R(t_i - t_i^*) = \begin{cases} 0.5 x^2 / \sigma & \text{if } |x| < 1 \\ |x| - 0.5 & \text{otherwise} \end{cases} \quad (5)$$

文中探讨的是工件的 Anchor 标定框的预测回归

过程, 建立的相关数学模型如式 (6) 所示:

$$\begin{cases} t_i = t_{xi} + t_{yi} + t_{wi} + t_{hi} \\ t_i^* = t_{xi}^* + t_{yi}^* + t_{wi}^* + t_{hi}^* \\ t_x = \frac{x - x_a}{w_a} & t_x^* = \frac{x^* - x_a}{w_a^*} \\ t_y = \frac{y - y_a}{h_a} & t_y^* = \frac{y^* - y_a}{h_a^*} \\ t_w = \log\left(\frac{w}{w_a}\right) & t_w^* = \log\left(\frac{w^*}{w_a^*}\right) \\ t_h = \log\left(\frac{h}{h_a}\right) & t_h^* = \log\left(\frac{h^*}{h_a^*}\right) \end{cases} \quad (6)$$

式中: t_x 、 t_y 为预选框中点坐标; t_w 、 t_h 分别为预选框宽度与高度; t_x^* 、 t_y^* 为标定框中点坐标; t_w^* 、 t_h^* 分别为标定框宽度与高度。将公式 (6) 代入公式 (5), 即可求出 Smooth L_1 损失函数。截取前 50 次网络迭代, 函数平滑效果如图 9 所示。




图 9 Smooth L_1 损失函数

Fig. 9 Smooth L_1 loss function

2.3.2 分类损失

分类损失函数可以近似为二分类交叉熵损失, 也叫对数损失, RPN 网络会选出相关 anchor 锚点, 前景的标签为 1, 背景的标签为 0。框内工件出现的概率可以表示为公式 (7):

$$P_i^* = \begin{cases} 0 & \text{Negative label} \\ 1 & \text{Positive label} \end{cases} \quad (7)$$

对数损失函数表示为式 (8):

$$L_{\text{CLS}}(P_i, P_i^*) = -\log [P_i P_i^* + (1 - P_i)(1 - P_i^*)] \quad (8)$$

由此可以计算出分类损失式 (9):

$$L(P_i, P_i^*) = \frac{1}{N_{\text{CLS}}} \sum_i L_{\text{CLS}}(P_i, P_i^*) \quad (9)$$

由公式 (5) 与公式 (9) 可计算出总体损失函数 $L(P_i, t_i)$, 将其编入程序中, 尽可能通过训练 epoch 次数实现较小 loss 函数, 得到较好的预测模型。

3 实验与结果

此实验使用 2 种不同的并联机器人实验平台, 原平台如图 2 所示, 改进模拟平台如图 10 所示。实验平台主要由 Delta 并联结构、CMOS 摄像头、测控计算机、工控机组成, 模拟实际工况下并联机构的运作

模式。其次考虑到并联机构的工作可达空间，摄像头安装在极限工作空间以外的区域，避免机构连杆与末端执行器触碰到摄像机。工业控制机用于机器人反应时间测量与使能控制。测控计算机用于图像处理与神经网络的搭建，基本配置为处理器 AMD R5-4600H，内存 16 GB（6 核），Cuda 环境为 GTX1650 显卡的 GPU。




图 10 实验平台基本架构

Fig. 10 Basic architecture of the experimental platform

文中通过 2 种不同的实验平台，对比原有系统与改进系统的标定时间与识别精度，原系统带有传统视觉系统，改进系统带有 Faster R-CNN 网络虚拟样机服务器。

打开光源与高速传送带，摄像头开始工作，先打开图 2 中 Delta 机器人实验台自带的物料识别软件进行实验，工件定位测试结果如图 11 所示。可以看出：工件识别效率很低，只有工件的区域标定而没有具体工件的识别，达不到并联机构拾取工件分类的目的。




图 11 原设备实验识别结果

Fig. 11 Experimental identification results of original equipment

将采集图像与预处理后的图像放入数据集中，原始图片为 500 张，经过数据处理后的图片达到了 500 张，进行数据增强图片 500 张，边缘处理图片 100 张做成单张图像小于 2 MB 的图像数据集，利用 Torch 中的 LabelImg 进行数据标定，选择使用 GPU 模式加快训练速度，放入 Python 与 OpenCV 环境下 Faster-RCNN-Pytorch 框架中进行训练，待训练完成后对验证集中的 60 张工件图像进行工件检测。图 12 所示为训练完成的部分结果。




图 12 工件识别结果

Fig. 12 Workpiece identification results

比起原有工件识别系统，Faster R-CNN 训练识别系统能够有效地识别具体工件，其中 3 种不同工件基本可以区分且置信度高，螺栓与螺母有少量检测错误。通过随机抽取 60 组图像数据，得出平均识别率如表 1 所示。

表 1 工件识别情况

Tab. 1 Workpiece identification

训练样本	样本个数	识别个数	平均识别率
工件 1	58	53	0.946
工件 2	52	47	0.904
工件 3	60	54	0.900
螺栓	72	68	0.944
螺母	69	65	0.942

由表 1 可得：工件检测结果平均精度约为 0.9，虽然比其他的 Faster R-CNN 网络训练结果置信度较低，但是在样本数据集自行制作的条件下得到了较为良好的识别效果，证明了这种检测方法的可行性。

使用 Pytorch-Python 计算相关评估，令阈值为 0.6，对召回率、精确率进行评估，如图 13 所示。可以看出：评估的精确率与召回率和实验的验证结果吻合度高。证明在样本集较小的情况下，经过图像增强与处理的工件图像训练出的网络精确度能保持高识别率的水平。




图 13 网络评估统计

Fig. 13 Network evaluation statistics

最后对识别反应时间进行相关实验,反应时间是指并联机器人识别工件时间,原系统识别与改进识别的对比如表 2 所示。

表 2 识别结果对比

Tab. 2 Comparison of recognition results

实验类别	平均反应时间/ms	平均精确率/%
原系统	83	/
原数据集	70	90.17
改进数据集	65	92.36

由表 2 看出:运用神经网络系统的模型虚拟样机的反应时间比原系统有所缩短,原系统无分类识别功能,因此不设置平均精确率。原数据集为 1 500 张原图数据集,改进数据集为预处理图像加原图像数据集,结果表明高质量的数据图片可以提高网络识别率,验证了图像处理的重要性与网络训练对于并联机构的优化。

4 结论与展望

文中使用图像预处理手段,制作出相关数据集,基于 Faster R-CNN 神经网络进行训练,主干提取网络选择 ResNet50 网络,在 Delta 机器人实验平台得出了较好的工件检测识别结果,而且识别精确度有所提升。文中的改进之处在于:

(1) 虽然 Faster R-CNN 网络模型识别平均置信度还有待提高,但是通过制作样本数目低的 VOC 数据集,完成了识别检测分类的基本工作。

(2) 在实际并联机构的工件识别定位中,文中考虑到了实验台的工作空间与噪声处理,进行大量对比实验,充分模拟实际环境下并联机构的工作情况。

(3) 通过实验验证了数据集图像处理的重要性,为神经网络中训练优化提供很好的思路。

Faster R-CNN 相对于 YOLO 最新系列框架而言,目前还不能够实现端到端操作,无法运用网络进行实时工况下 Delta 机器人的监测与定位,而且只进行识别与分类,相关控制功能还未能实现。但并联机构与神经网络结合研究相对较少,文中系统性进行了大量 Delta 并联机构与神经网络的结合对照实验,对并联机构智能化应用具有一定的参考价值。

参考文献:

- [1] 杨桂华,刘志毅,王晓文.基于机器视觉多目标工件分类识别和定位研究[J].机床与液压,2021,49(11):82-86.
YANG G H,LIU Z Y,WANG X W.Research on classification,recognition and localization of multi-objective work-piece based on machine vision[J].Machine Tool & Hydraulics,2021,49(11):82-86.
- [2] 梅江平,王浩,张舵,等.基于单目视觉的高速并联机器人动态目标跟踪算法[J].天津大学学报(自然科学与工程技术版),2020,53(2):138-146.
MEI J P,WANG H,ZHANG D,et al.Dynamic target tracking algorithm of a high-speed parallel robot based on

monocular vision[J].Journal of Tianjin University (Science and Technology),2020,53(2):138-146.

- [3] 王彦.基于视觉的机械手目标识别及定位研究[D].西安:西安理工大学,2010.
WANG Y.Research on target recognition and location of manipulator based on computer vision[D].Xi'an:Xi'an University of Technology,2010.
- [4] GAO Y,CHEN K,GAO H,et al.Energy consumption prediction for 3-RRR PPM through combining LSTM neural network with whale optimization algorithm[J].Mathematical Problems in Engineering,2020,2020:6590397.
- [5] 李琦.三自由度并联机器人运动性能分析与视觉应用[J].组合机床与自动化加工技术,2019(7):88-91.
LI Q.Performance analysis and visual application for 3-DOF parallel robot[J].Modular Machine Tool & Automatic Manufacturing Technique,2019(7):88-91.
- [6] 张磊,王树才.基于 Delta 并联机器人的禽蛋智能捡拾试验[J].华中农业大学学报,2018,37(3):117-124.
ZHANG L,WANG S C.Studies on experimental device of egg intelligent handling based on parallel[J].Journal of Huazhong Agricultural University,2018,37(3):117-124.
- [7] 刘亮.基于深度学习的视觉运动估计与理解[D].杭州:浙江大学,2021.
LIU L.Deep learning-based visual motion estimation and understanding[D].Hangzhou:Zhejiang University,2021.
- [8] 王帅.基于机器视觉的产品表面缺陷检测关键算法研究[D].北京:中国科学院大学(中国科学院沈阳计算技术研究所),2021.
WANG S.Research on key algorithm of product surface defect detection based on machine vision[D].Beijing:Institute of Computing Technology,Chinese Academy of Sciences,2021.
- [9] UYAR K,TAŞDEMİR Ş,ÜLKER E,et al.Multi-Class brain normality and abnormality diagnosis using modified Faster R-CNN[J].International Journal of Medical Informatics,2021,155:104576.
- [10] WU Y R,LIU W,WAN S.Multiple attention encoded cascade R-CNN for scene text detection[J].Journal of Visual Communication and Image Representation,2021,80:103261.
- [11] 高文婷,刘越.面向移动增强现实的实时深度学习目标检测方法综述[J].图学学报,2021,42(4):525-534.
GAO W T,LIU Y.Review of real-time deep learning-based object detection for mobile augmented reality[J].Journal of Graphics,2021,42(4):525-534.
- [12] 范丽丽,赵宏伟,赵浩宇,等.基于深度卷积神经网络的目标检测研究综述[J].光学精密工程,2020,28(5):1152-1164.
FAN L L,ZHAO H W,ZHAO H Y,et al.Survey of target detection based on deep convolutional neural networks[J].Optics and Precision Engineering,2020,28(5):1152-1164.